

Título: Modelo de clasificación para predecir la mora bancaria.

Introducción

Características y motivación del proyecto

Este proyecto desarrolla un modelo de clasificación aplicado al área de gestión de riesgo crediticio, abordando un problema de aprendizaje supervisado orientado a estimar la probabilidad de mora de nuevos clientes.

La mora en el cumplimiento de obligaciones crediticias constituye un fenómeno recurrente dentro de la actividad financiera y, bajo determinados niveles, forma parte del funcionamiento normal del sistema bancario. Sin embargo, en contextos de recesión económica, inflación elevada y deterioro del poder adquisitivo, el incremento sostenido de la morosidad puede afectar negativamente la rentabilidad, la liquidez y las expectativas de los inversores sobre las entidades financieras.

En los últimos años, distintas entidades financieras y fintechs registraron incrementos significativos en sus niveles de mora, especialmente en segmentos de consumo y crédito personal. Estos procesos evidencian las dificultades de los sistemas tradicionales de evaluación crediticia para anticipar cambios bruscos en el comportamiento de pago de los clientes en contextos de elevada incertidumbre macroeconómica.

Habitualmente, las entidades financieras evalúan el riesgo crediticio mediante instrumentos como el score bancario y la clasificación financiera del cliente, los cuales se basan principalmente en el historial financiero y el comportamiento previo de pago. Si bien estos mecanismos resultan eficaces en contextos relativamente estables, pueden presentar limitaciones para capturar cambios recientes en las condiciones económicas y financieras de los individuos.

En este contexto, el área de riesgo crediticio enfrenta un desafío central: mejorar la capacidad de identificar clientes con elevada probabilidad de incumplimiento sin restringir excesivamente el otorgamiento de crédito. A partir de esta problemática, el presente proyecto propone desarrollar un modelo de clasificación basado en técnicas de Machine Learning, capaz de segmentar clientes según su probabilidad estimada de incurrir en mora y contribuir a una toma de decisiones crediticias más eficiente.

Puntos críticos del negocio crediticio:

Masividad de Clientes morosos:

- Se otorgan créditos masivos de montos relativamente bajos que no tienen retorno en los plazos esperados.

Créditos no pagados:

- Un porcentaje de los clientes morosos no pagan sus créditos y la probabilidad de recuperación es baja.

Objetivo General

El objetivo de este proyecto es crear un modelo de clasificación que prediga qué clientes son candidatos a incurrir en mora y, a partir de ello, clasificar el riesgo de asignación de nuevos créditos.

Objetivos Específicos:

- Describir las principales variables financieras y sociodemográficas de los receptores de crédito.
- Analizar cómo se relaciona la mora con el perfil financiero y sociodemográfico del cliente.
- Crear un modelo de clasificación utilizando random forest que prediga la probabilidad de mora.
- Segmentar a los clientes según el riesgo a incurrir en mora.

Perfil del cliente beneficiario:

La solución de este proyecto va dirigida a distintas áreas de una compañía:

Área de riesgo crediticio → Mejorar políticas de aprobación de créditos.

Área comercial → Ofrecer productos adecuados al riesgo crediticio del cliente.

Área de cobranzas → Campañas preventivas y renegociación crediticia.

Adquisición de datos:

Se utiliza un dataset de datos crediticios de Perú descargado de la plataforma Kaggle. El dataset cuenta con una dimensión de 8399 filas y 14 columnas. Tras la limpieza de datos, transformación de valores y creación de nuevas variables el dataset adquiere una dimensión de 6074 filas y 29 columnas.

La razón por la cual se selecciona este dataset radica principalmente en que se encuentra disponible para descargar y cuenta con más de 70% de clientes con mora, lo que lo hace un dataset significativo para el análisis de "mora masiva".

No obstante, la falta de información acerca del origen de los datos alerta sobre la fiabilidad del mismo. El elevado porcentaje de morosos y otras inconsistencias detectadas advierten

de elevadas probabilidades de que se trate de un dataset sintético. A pesar de estas inconsistencias, como el objetivo de este proyecto es formativo, intentaremos subsanar los déficits del dataset con el conocimiento y las habilidades aprendidas.

El dataset contiene información demografica y de perfil crediticio en 8399 clientes. Estas variables pueden agruparse de la siguiente manera:

Grupo	Variable	Descripción
Demográficas	Vivienda, Edad, Días_lab, Ingresos, Zona, Nivel_educ, Nivel_ahorro	Perfil sociolaboral del cliente
Riesgo crediticio	Mora, Atraso, Deuda_sf, Score Calificación, Clasif_sbs	Perfeil de riesgo crediticio del cliente
Experiencia financiera	Línea_sf, Exp_sf	Experiencia con productos financieros

Descripción de variables

Vivienda	Tipo de vivienda del cliente
Edad	Edad del cliente
Días_lab	Días laborados en su actual empleo
Nivel_ahorro	Índice del nivel de ahorro del cliente (de 0 a 12. 0: no tiene ahorros, 12: alto nivel de ahorros)
Ingreso	Ingresos del cliente
Zona	Departamento de residencia del cliente
Nivel_educ	Nivel educativo máximo alcanzado por el cliente
Mora	Morosidad del cliente (0: paga al día, 1: cliente moroso)
Atraso	Atraso histórico del cliente en días

Deuda_sf	Deuda del cliente en el sistema financiero
Score	Calificación del cliente. Mientras mayor es el score, mejor perfil crediticio tiene el cliente
Clasif_sbs	Mientras mayor es el número, peor clasificación tiene el cliente: {0: normal, 1: con problemas potenciales, 2: deficiente, 3: dudoso, 4: pérdida}
Exp_sf	Meses con experiencia en el sistema financiero, es decir el número de meses que tiene el cliente desde que adquirió algún producto financiero
Línea_sf:	Línea de crédito en el sistema financiero que el cliente tiene disponible

Variable objetivo: “mora”.

Técnica de análisis supervisado elegido: Modelo de clasificación (Random Forest)

El objetivo de este trabajo es entrenar un modelo capaz de predecir la probabilidad de mora de un cliente. Para ello se emplea un método de aprendizaje supervisado, dado que se dispone de datos etiquetados que permiten entrenar el modelo a partir de una variable objetivo ("mora").

Dentro de este enfoque se utiliza un modelo de clasificación basado en el algoritmo Random Forest ("bosque aleatorio"). Este método construye múltiples árboles de decisión que, de manera conjunta, estiman la probabilidad de que un cliente incurra en mora. Cada árbol aprende patrones distintos a partir de subconjuntos aleatorios de observaciones y variables, y posteriormente sus resultados se combinan para producir una clasificación final.

Una de las principales ventajas de este algoritmo es su capacidad para capturar relaciones complejas y no lineales entre las variables, así como interacciones entre distintos factores financieros y sociodemográficos. Además, el método suele presentar un buen desempeño predictivo en problemas de clasificación con datos desbalanceados y permite evaluar la importancia relativa de las variables utilizadas en la predicción.


Índice del proyecto.

1. Análisis Exploratorio de datos (Univariado, Bivariado, Multivariado)
2. Evaluación del modelo (Random Forest)
3. Resultados de Clasificación de riesgo de mora
4. Conclusiones y Recomendaciones de Negocio

1. Análisis exploratorio de datos


Análisis univariado

Distribución de la Variable Clave 'Mora'



La variable objetivo “Mora” se distribuye de manera asimétrica:

- 71% Mora
- 29% No mora.




Distribución de edad es ligeramente asimétrica.

La media de los clientes es de 36 años de edad y la mediana de 34 años, lo que representa una clientela joven.

La edad mínima de los clientes es de 20 años y la máxima de 80. A partir de los 35 años tiende a decrecer el número de clientes de manera no lineal.

Perfil demográfico: nivel educativo, tipo de vivienda y residencia


Variables Categóricas — Perfil Demográfico



La mayoría de los clientes poseen una formación alta: universitaria (54%) y técnica (44%). Muy pocos clientes alcanzaron únicamente la educación secundaria o ninguna instrucción.

Habitan principalmente una vivienda familiar (64%), seguido de una vivienda propia (24%) y, en muy pocos casos una vivienda alquilada (2%).


El grueso de los clientes residen en la costa (80%), principalmente en Lima, seguido por Sierra y Selva.



La distribución de ingresos es asimétrica con sesgo positivo.


La media se ubica en 4.138 y la mediana en 2.226. Esto implica que la mayoría de los clientes poseen ingresos de medios a bajos y una minoría tiene ingresos elevados que llegan a alcanzar la cifra de 30.000 Soles.

Distribución de línea de financiamiento



La línea de financiamiento que reciben los clientes se concentra en montos medios a bajos. La media es de 9.745 y la mediana de 3.725, aunque algunos clientes pueden recibir créditos de 120.000 Soles.


Esto implica que la mayoría de los clientes recibe líneas de financiamiento de bajo monto, mientras pocos clientes reciben financiaciones por montos elevados.



Los clientes poseen poca experiencia en el sistema financiero.

Los casos se concentran entre 0 y 2 años de experiencia. De hecho, la media y la mediana es de 2 años y la antigüedad máxima alcanza los 10 años.


Distribución de la deuda




La deuda de los clientes se ubica en montos medianos a bajos.

La media es de 5.586 y la mediana de 2.297. Existen una gran cantidad de valores extremos que superan los 20.000 soles.

En relación al gráfico anterior “distribución de Línea de Financiamiento”, la deuda es menor a la línea de financiamiento recibida, lo que indica que a pesar de existir mora, los clientes tienden a abonar parte de los compromisos financieros asumidos.




El nivel de ahorro se concentra mayormente en clientes con alta capacidad de ahorro (12). Los clientes con media, poca o nula capacidad de ahorro son muy minoritarios. Este dato es llamativo ya que la capacidad de ahorro contrasta con el nivel de mora elevado que presenta el dataset.



El score –clasificación crediticia– de los clientes tiene una distribución casi simétrica: la media y la mediana se ubican en 196 puntos. Se observa que el conjunto del score del cliente es bajo (Score mide entre 0 y 999).


Clasificación



La distribución de la clasificación de los clientes son positivas y se concentran principalmente en 0 y 1. Por su parte, los clientes mal calificados y considerados “pérdidas” ocupan una posición minoritaria de la base (3 y 4).

Llama la atención que habiendo 70% de clientes con mora, las calificaciones medias a bajas cuentan con menos de 500 casos cada una.


Mora según perfil sociodemográfico



Distribución de mora según variables sociodemográficas seleccionadas. La mora no se distribuye de manera uniforme en las variables sociodemográficas seleccionadas. Por el contrario:

- Según el tipo de vivienda, zona de residencia y nivel educativo alcanzado cambia la distribución de la mora.
- Se observa que habitar una **vivienda “alquilada”, residir en zona “selva” y alcanzar los estudios “secundarios”** como máxima instrucción, **incrementan la probabilidad de mora.**
- De manera opuesta, habitar una **vivienda propia, residir en la “costa” o la “sierra” y poseer “estudios universitarios”** **reducen la probabilidad de mora.**
- No obstante, en todos los casos, la mora supera un 60% de la distribución.


Distribución de mora según variables financieras seleccionadas



La visualización de boxplot de mora según variables financieras seleccionadas (ingreso, experiencia en el sistema financiero, score y línea de financiamiento) permite observar cómo varían medidas de tendencia central en mora y no mora:


- **Ingresos:** la media de ingresos es menor en clientes morosos
- **Experiencia en el sistema financiero:** clientes con menor experiencia financiera son más propensos a la mora.
- **Score:** clientes con score más bajo tienden a tener mayor mora
- **Línea de financiamiento:** Clientes morosos tienden a recibir líneas de financiamiento menor, aunque predomina un gran número de casos extremos (morosos con financiación elevada)

Distribución de mora según score y clasificación



La mora no se distribuye de manera uniforme según score y clasificación:


- **Score:** se presentan mayor concentración de casos con mora en scores bajos
- **Clasificación:** la mora es mayor entre los clientes peor clasificados (4).
- No obstante, se encuentra una mora elevada en todos los niveles de clasificación y de score, aunque en este último caso en menor medida
- Este gráfico alerta sobre los sistemas de evaluación de clientes en los que la mora tiene una incidencia poco o nada significativa.



La correlación positiva y negativa no supera el 0.25 sobre 1. De este modo, se observa que **no existe una correlación significativa entre mora y el resto de las variables del dataset** que permita inferir una única variable explicativa de la mora. Este hallazgo justifica la creación de un modelo de machine learning que prediga la mora a partir de la decisión de multiples árboles.

- Las variables de mayor correlación positiva son: ingreso, exp_sf, score, exp_sf_anios (equivalente a exp_sf) y linea sf
- Las variables de mayor correlación negativa son ratio_linea, atraso, exp_sf_missing y clasif_sbs


Análisis multivariado: Mora según variables seleccionadas



Los gráficos de dispersión según variables financieras por mora no identifican visualmente grupos separados de mora y no mora. Por el contrario, los datos presentan una gran dispersión.

Ingreso vs. variables financieras y laborales seleccionadas

Relaciones financieras y laborales




Se profundiza el análisis de “ingresos”, una de las variables que mayor correlación presenta con mora.

Si bien la mayoría de los clientes posee ingresos de medios a bajos, observamos que su distribución no es homogénea en las variables seleccionadas.

- **Ingreso según deuda:** Ingresos y Deuda suelen concentrarse en montos medios a bajos y tienden a crecer linealmente, aunque existen casos extremos (ingresos bajos y deuda alta y deuda baja con ingresos altos).
- **Ingresos según años en sistema:** Los ingresos menores tienden a concentrarse en menores años en el sistema y la tendencia es que crezcan juntos, aunque existen casos extremos (poca experiencia con altos ingresos y mucha experiencia con bajos ingresos)
- **Ingresos según línea financiera:** la financiación crece según los ingresos, aunque la mayoría de las líneas financieras corresponden a clientes de ingresos medios a bajos.
- **Ingresos según años trabajadores:** los ingresos tienden a crecer según los años de trabajo.


Ingresos según variables sociodemográficas seleccionadas

Relaciones sociodemográficas



Si bien la mayoría de los clientes posee ingresos de medios a bajos, observamos que su distribución no es homogénea en las variables seleccionadas.

- **Ingreso según nivel educativo:** Los universitarios concentran los mayores ingresos, seguida por la secundaria y la técnica. Es llamativo que la técnica tenga una mediana menor que secundaria, aunque esto puede deberse a los pocos casos que concentra educación secundaria (2% del total). Hay una anomalía en "sin educación" que rompe el patrón del boxplot, aunque hay pocos datos (0.5%).
- **Ingresos según vivienda:** vivienda propia posee mayores ingresos y familiar los menores.
- **Ingresos según nivel de ahorro:** los boxplot son dispares, no se observa una correspondencia clara entre nivel de ingreso y ahorro.
- **Ingresos según edad:** los ingresos tienden a crecer moderadamente según la edad del cliente y ser mayores entre el segmento de 40 a 50 años.



El boxplot de score según clasificación de clientes muestra que la media de score es relativamente similar entre las distintas clasificaciones. Incluso, clientes con calificación negativa (4) poseen un score medio superior a clientes con clasificación positiva (0: normal, 1: con problemas potenciales, 2: deficiente, 3: dudoso, 4: pérdida).

Esta anomalía sugiere que score o clasificación no logran medir eficientemente el riesgo crediticio y puntaje real del cliente.

Modelo de clasificación y evaluación

Se compararon dos modelos de clasificación: Logistic Regression y Random Forest, utilizando validación cruzada estratificada. El modelo Random Forest obtuvo un desempeño superior, alcanzando un F1-score promedio de 0.84 frente a 0.75 de la regresión logística. Estos resultados sugieren que la mora bancaria depende de relaciones complejas y no lineales entre las variables analizadas, las cuales son capturadas de manera más eficiente por Random Forest.


Modelo	Desempeño
Regresión logística	0.75
Random Forest	0.84

Posteriormente, el modelo fue optimizado mediante RandomizedSearchCV, obteniéndose como mejor configuración un bosque de 300 árboles con restricciones moderadas sobre el crecimiento de los nodos. El modelo final alcanzó un F1-score de 0.85 para la clase “mora”, junto con un recall de 0.87, indicando una elevada capacidad para identificar clientes con riesgo de incumplimiento crediticio.

	precision	recall	f1-score	support	
0		<u>0.64</u>	<u>0.56</u>	<u>0.60</u>	<u>352</u>
1		<u>0.83</u>	<u>0.87</u>	<u>0.85</u>	<u>863</u>
accuracy				<u>0.78</u>	<u>1215</u>
macro avg		<u>0.74</u>	<u>0.72</u>	<u>0.72</u>	<u>1215</u>
weighted avg		<u>0.77</u>	<u>0.78</u>	<u>0.78</u>	<u>1215</u>

Si bien el modelo presentó menores niveles de desempeño para identificar clientes no morosos, logró un equilibrio general razonable entre sensibilidad y precisión, alcanzando una accuracy global de 0.78 y un macro average F1-score de 0.72.


Árbol de decisión dentro del Random Forest



El árbol muestra que:

- el score es el principal organizador del riesgo.
- luego intervienen ingreso, deuda, ahorro y experiencia financiera,
- y el modelo construye perfiles combinados de vulnerabilidad financiera

Matriz de confusión — Random Forest optimizado




Matriz de confusión

La matriz de confusión complementa el reporte de clasificación. Evalúa el rendimiento de un modelo de clasificación comparando las predicciones realizadas con los valores reales.

Predicción	Acierto	Error	Total	Analisis
Mora	754 (82%)	156 (18%)	910 (100%)	El modelo tiene una gran capacidad de predecir la mora


No mora	196 (64%)	109 (36%)	305 (100%)	El modelo tiende a calificar clientes un porcentaje menor, pero significativo de no morosos como mora
---------	-----------	-----------	------------	---

La matriz de confusión evidencia que el modelo tiene una gran capacidad de predecir la mora (82% de aciertos), pero tiende a considerar una tercera parte de clientes no morosos como morosos.




Dado el desbalance existente entre clientes morosos y no morosos, se incorporaron métricas robustas para clasificación desbalanceada, tales como Balanced Accuracy, Matthews Correlation Coefficient y Cohen's Kappa, con el objetivo de evaluar el desempeño real del modelo más allá de la accuracy general


Metrica	Descripción	Resultado	Interpretación
Balanced Accurac	Equilibra la accuracy en dataset desbalanceados. Su propósito es asegurar que el modelo funcione bien en las clases minoritarias	0.70	El modelo logra balancear bien la clase mayoritaria y la minoritaria
MCC (Matthews Correlation Coefficient)	Evalua la calidad de las clasificaciones binarias en el aprendizaje automático. Una puntuación MCC alta solo se consigue si un modelo funciona bien tanto en la clase mayoritaria como en la minoritar	0.46	Correlación razonable (-1 totalmente incorrecto, 0 azar, 1 perfecto)
Cohen's Kappa	evalúa cuánto mejora el modelo respecto al azar	0.44	El modelo mejora los resultado en relación al azar




- Roc-AUC evalúa que tan eficaz es el modelo para separar a morosos y no morosos.
- ROC-AUN de 0.81 implica que el modelo es muy bueno en separar ambas clases.



- PR-AUC evalúa la capacidad de mantener la "precisión" mientras aumenta "recall"
- PR-AUC de 0.90 implica que el modelo es "excelente" en lograr captar muchos morosos sin perder totalmente precisión.



- Las importancias combinan variables sociodemográficas y variables financieras
- Las variables más importantes son Ingreso, score, linea_sf, ratio_deduda y edad.
- Variables como nivel educativo, zona de residencia y tipo de vivienda tienen menor importancia en los árboles.



Permutation importance evalúa cuánto depende el rendimiento predictivo del modelo de esa variable una vez entrenado.

- Observamos que tres variables que encabezan feature importance también lo hacen en permulance importance: Ingreso, score, linea_sf. Sin embargo, atraso y clasif_sbs ocupan una posición de mayor importancia que ratio_deduda y edad.
- Permutatation importance cmlplementa y convalida feature importance


Resultados de segmentación de riesgo de mora

Una vez evaluado el modelo Random Forest realizamos una segmentación probabilística según la posibilidad de incurrir en mora y segmentamos el dataset de testeo en cinco perfiles crediticios, según el riesgo: bajo, medio bajo, medio, medio alto y alto.

SEGMENTO	CANTIDAD	PORCENTAJE
Bajo	9	1
Medio Bajo	88	7
Medio	238	20
Medio Alto	439	36
Alto	441	36
Total	1215	100

La segmentación de clientes ubica al 72% con riesgo elevado, 20% riesgo medio y 8% con bajo riesgo de mora. Esta distribución se asocia al porcentaje de mora (71%) y no mora (29%) del dataset


Distribución de segmentos según variables categóricas



La distribución del perfil crediticio del cliente observa mayores porcentajes de clientes con riesgo elevado según variables seleccionadas:


- **Años trabajados:** El riesgo baja a medida que aumenta la experiencia laboral.
- **Experiencia en el sistema financiero:** el riesgo baja a medida que crece la experiencia en el sistema financiero. Observamos que a partir de los 9 años el riesgo elevado desaparece.
- **Clasificación:** A mayor calificación (0 y 1) se observa menor riesgo.
- **Nivel de ahorro:** el riesgo se distribuye de forma asimétrica. Sin embargo, esta variable se encuentra colonizada por alto nivel de ahorro (12) lo que afecta los casos de menor ahorro.

Perfil financiero y sociodemográfico según riesgo



El boxplot y paiploot distinguen los distintos segmentos de riesgo:

- **Ingresos:** a medida que los ingresos crecen el riesgo crediticio se reduce
- **Score:** se observa que a medida que baja el score crece el riesgo
- **Edad:** existe mayor concentración de riesgos en edades menores, cercanas a los 20 años
- **Línea de financiamiento:** Las líneas de menor financiamiento concretan mayor riesgo, aunque existe una gran cantidad de outliers en riesgo medio, medio alto y alto..
- **Deuda:** el riesgo suele distribuirse de forma similar según la deuda, aunque existen más datos extremos en riesgo medio, medio alto y alto.



El heatmap resume el perfil promedio de los distintos segmentos de riesgo identificados por el modelo. Los clientes clasificados como bajo riesgo presentan mayores ingresos, mejor score crediticio, mayor edad y menor nivel de endeudamiento promedio. En contraste, los segmentos de alto riesgo muestran menores ingresos, peores scores y menor capacidad de ahorro, sugiriendo una mayor vulnerabilidad financiera estructural.

Ingreso:

- Los clientes de segmento de "riesgo bajo" tienen un promedio de ingresos de \$10.993.
- Por el contrario, en el segmento de "riesgo alto" el promedio es de \$2577

Score:

- En el segmento de "riesgo bajo" el Score promedio es alto (220).
- Por el contrario, segmento de "riesgo alto" tiene un promedio menor (184)

Edad:

- Riesgo bajo encuentra edades maduras (promedio 41-47 años).
- Por el contrario, en riesgo alto, el promedio de edad es menor (promedio 33-36)

Deuda:

- En bajo riesgo el promedio de deuda es de \$2100 y en riesgo alto de \$5121. Esto indica que a mayor deuda más riesgo de mora. Sin embargo, a diferencia de las anteriores variables, la deuda no crece linealmente por segmento

Conclusiones y Recomendaciones de Negocio

El incumplimiento de obligaciones financieras constituye uno de los principales riesgos de las entidades financieras ya que impacta negativamente sobre la rentabilidad, el valor bursatil y la recuperación de créditos. En este contexto, el objetivo de este proyecto fue desarrollar un modelo capaz de estimar la probabilidad de mora de los clientes a partir de técnicas de aprendizaje supervisado. El punto de partida fue la inquietud acerca de la eficacia de los instrumentos de clasificación de clientes vigentes en captar la probabilidad de mora.

El Analisis exploratorio de datos permitio identificar un perfil de cliente mayormente joven (Edad entre 30 a 40 años), con formación técnica y universitaria, residente mayormente en la costa y habitantes de viviendas familiares. Desde el punto de vista del perfil financiero, los ingresos, línea de financiamiento y deuda se concentran en montos medios a bajos, aunque existe una minoría con montos elevados. Asimismo, la experiencia en el sistema financiero es baja –mayormente entre 0 y 2 años- y los clientes son calificados mayormente como clientes “normales”, aunque poseen un score bajo (media 190)

Para la clasificación de implemento un modelo Random-Forest que permitió diferenciar de manera eficientes grupos morosos de no morosos. El modelo acerto en el 91% de clientes morosos y en un 49% de clientes sin mora. Esto implica que el algoritmo es muy bueno acertando clientes con mora, pero tiende a sobreestimar parcialmente la probabilidad de mora, acusando a clientes no morosos de riesgo crediticio.

El analisis de árbol de decisiones y de importancias identifica que las variables más significativas del modelo fueron: ingreso, score, línea y ratio de deuda. Estos resultados sugieren que el riesgo crediticio se encuentra fuertemente asociado tanto a la capacidad económica del cliente como a su historial financiero .El nivel educativo alcanzado, la zona de residencia y el tipo de vivienda fueron menos relevantes. La menor importancia en estas variables corresponde a la distribución fuertemente sesgada que presenta el dataset.

Finalmente, se realizó una segmentación probabilística del riesgo de mora, clasificando a los clientes en cinco perfiles: bajo, medio bajo, medio, medio alto y alto riesgo. Esta segmentación permitió identificar perfiles financieros y sociodemográficos diferenciados, observándose que los clientes de mayor riesgo presentan menores ingresos, peores scores crediticios, menor capacidad de ahorro y menor antigüedad dentro del sistema financiero. En comparación con la “clasificación” originaria del dataset y el score del cliente, esta segmentación permitió diferenciar con mayor claridad los perfiles de riesgo.

Desde el punto de vista de negocio, el modelo desarrollado puede contribuir a mejorar los mecanismos de evaluación crediticia, permitiendo optimizar políticas de otorgamiento, seguimiento y prevención de riesgo. Asimismo, la segmentación probabilística puede utilizarse para diseñar estrategias diferenciadas de monitoreo y gestión de clientes según su perfil de riesgo.

